

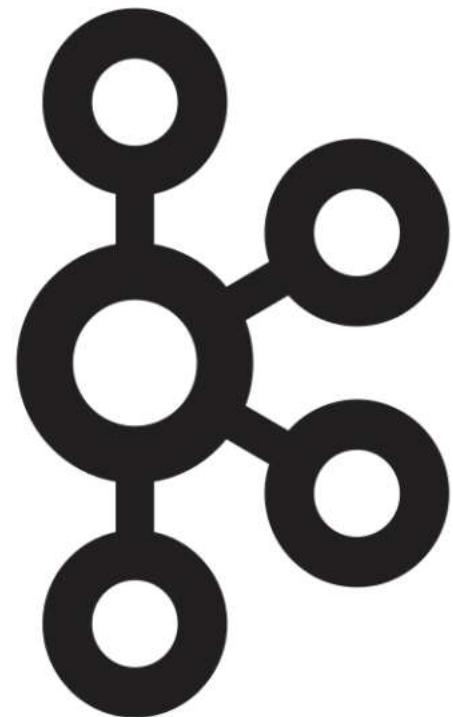
Очередь сообщений Kafka. Spark Streaming

LSML #3

Что сегодня изучим?

- Очереди сообщений
- Apache Kafka
- Подход – micro batch streaming
- Spark streaming
- Примеры реализации стримингового ETL

Шина данных Kafka



kafka

Очередь сообщений

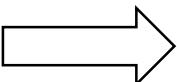
Решение для передачи, временного хранения и обработки данных в режиме реального времени. Часто используются для распределения данных между различными приложениями или компонентами системы. Широко используется для стриминговой обработки данных, создания централизованных журналов событий и реализации архитектур "событие-ориентированных" систем

Очередь сообщений



Модели очередей

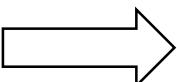
PULL



Инициатива запроса данных: получатель запрашивает данные у отправителя по мере необходимости. Получатель активно инициирует запрос данных.

Примеры: запросы к базе данных, загрузка вебстраниц, клиент-серверное взаимодействие, где клиент запрашивает данные у сервера.

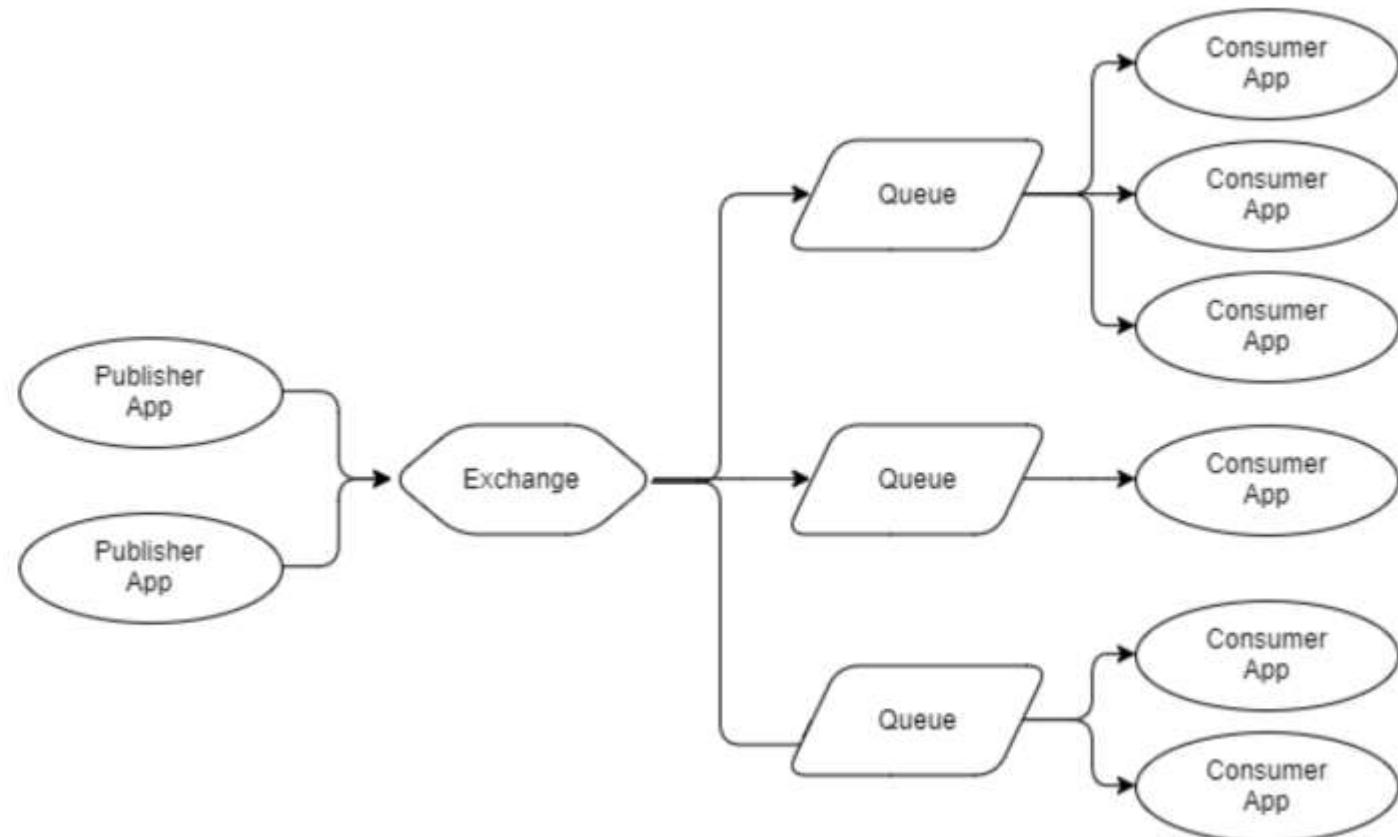
PUSH



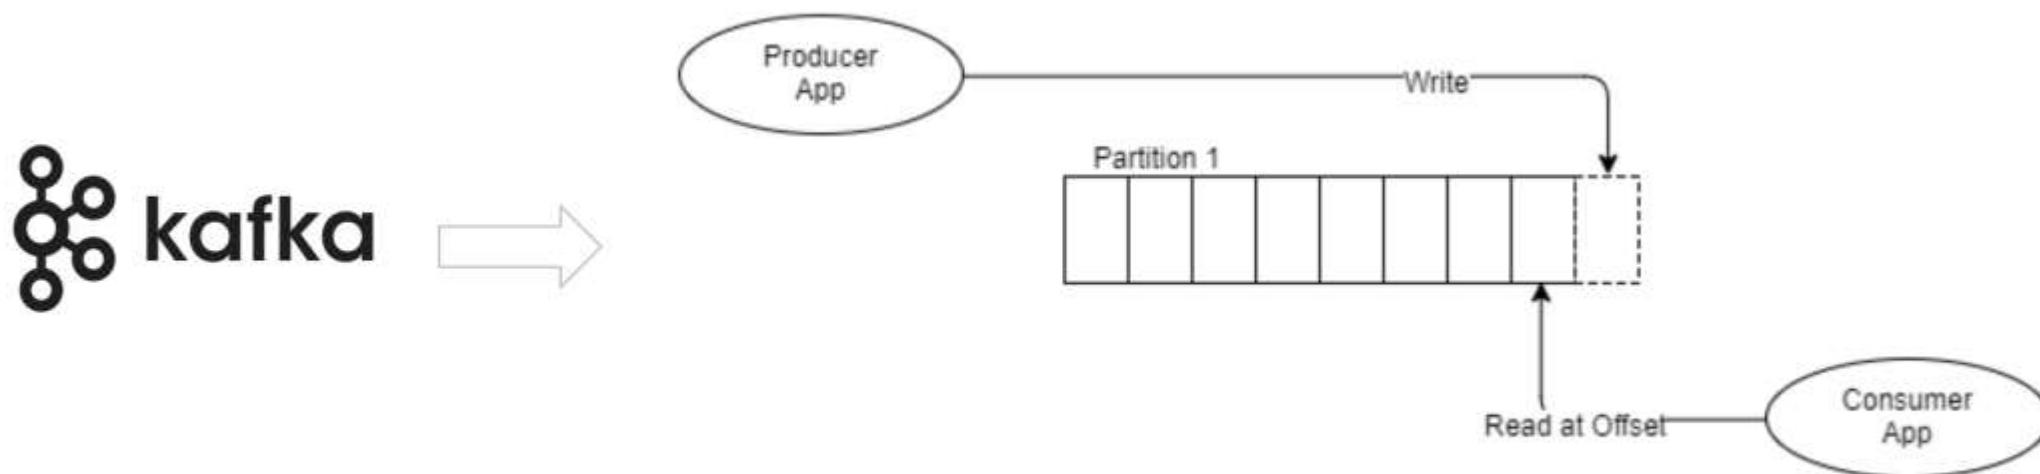
Инициатива передачи данных: данные передаются от отправителя к получателю без запроса со стороны получателя.

Примеры: уведомления на мобильных устройствах, рассылка электронной почты, стриминговые сервисы, где данные активно отправляются клиенту

PUSH-модель



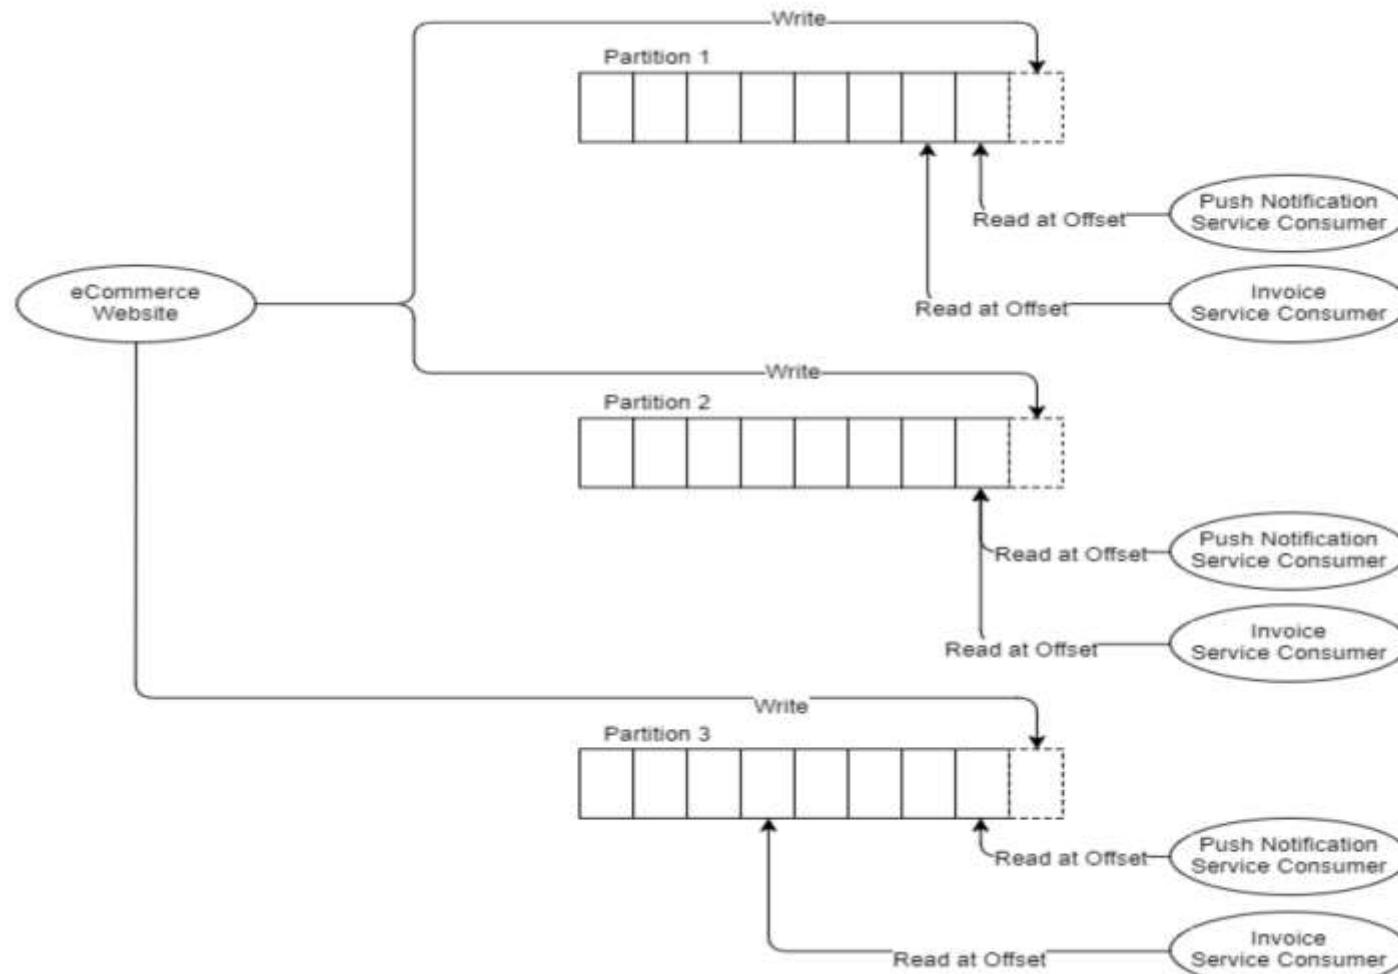
PULL-модель



Определение Apache Kafka

Распределенная платформа, которая предоставляет высокопроизводительное, надежное и масштабируемое решение для передачи, хранения и обработки данных в реальном времени. Шина данных Kafka позволяет управлять потоками данных с использованием тем (topics) для организации информации и разделения ее между различными приложениями или компонентами системы

Прицип работы Kafka



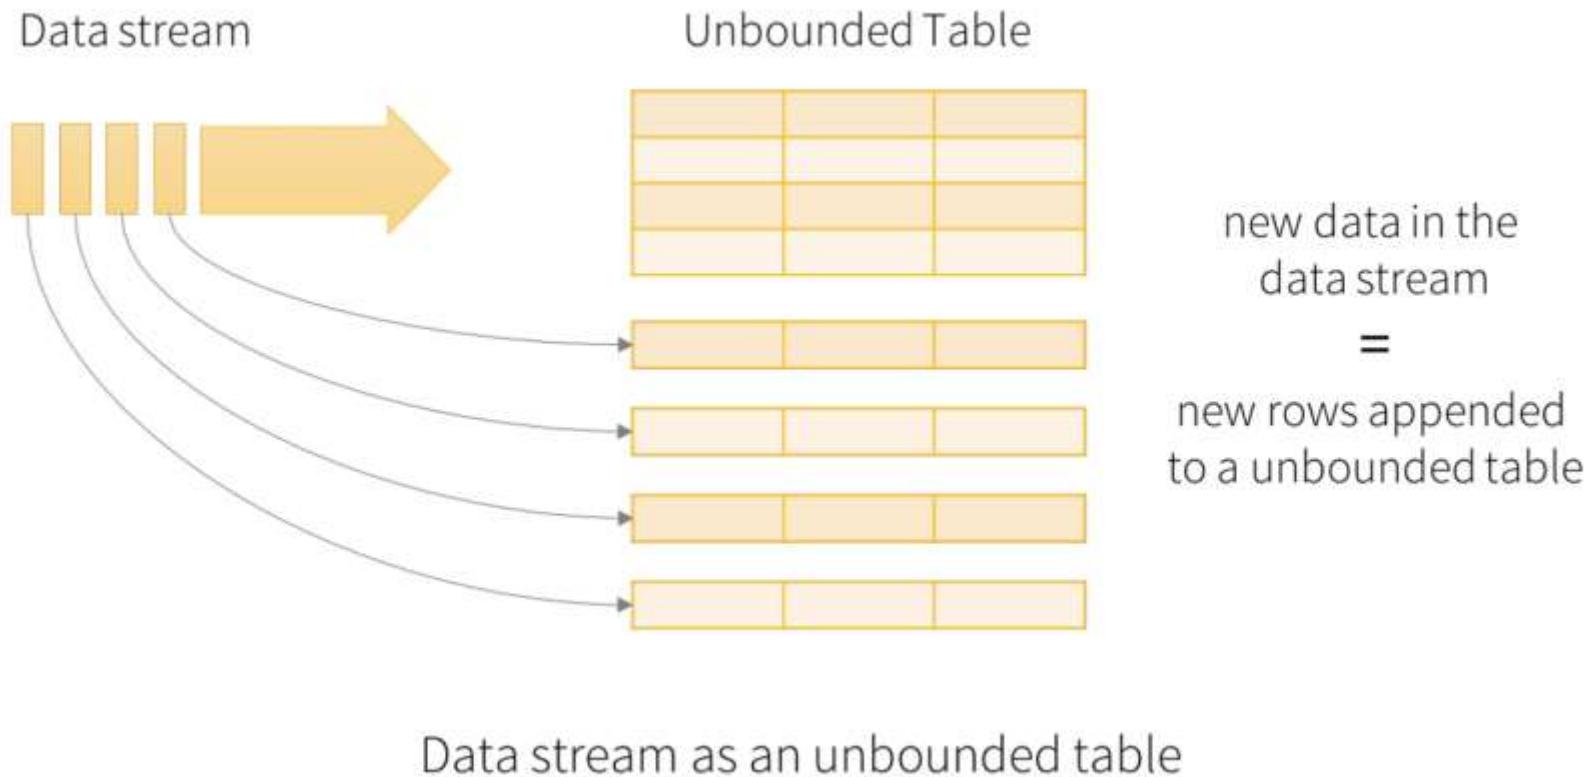
Spark Streaming

Micro batch streaming

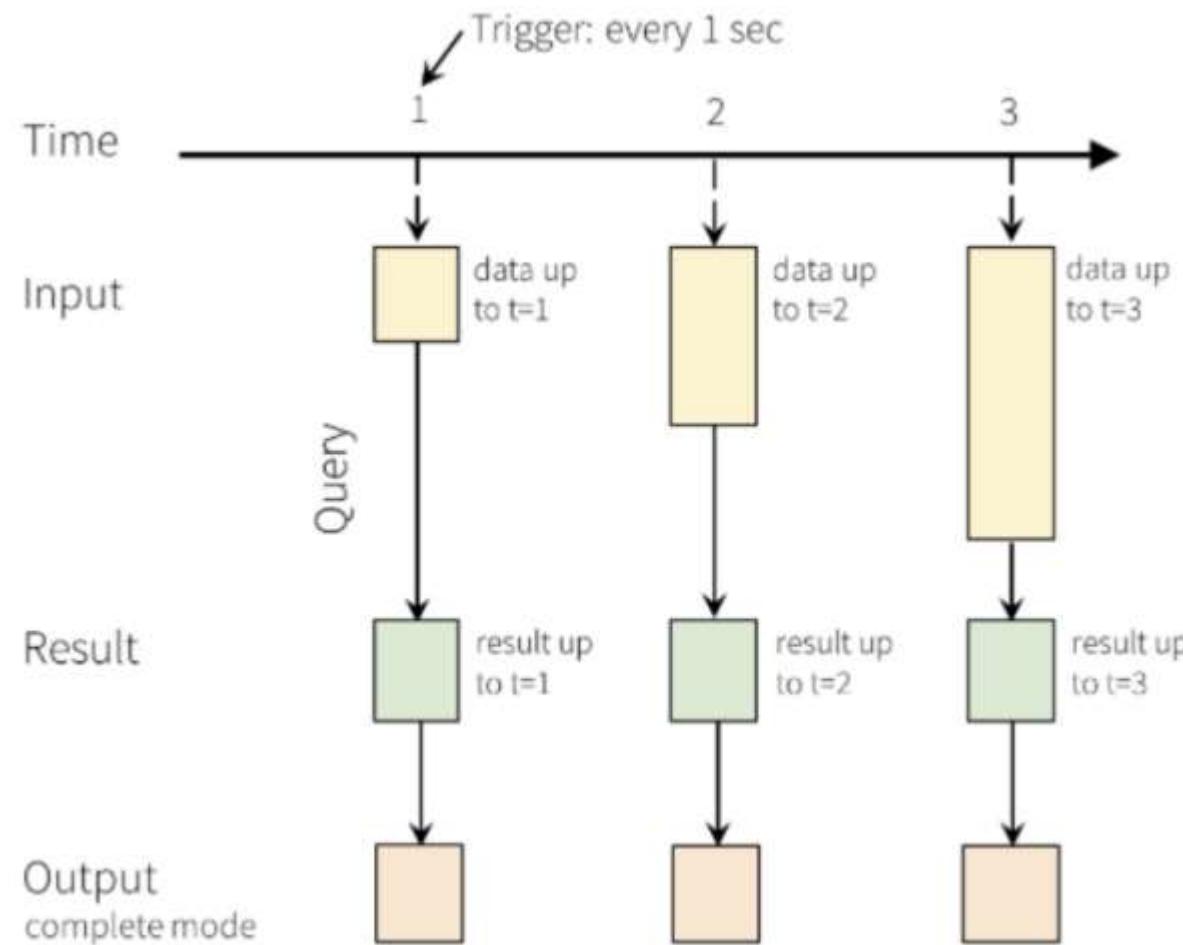
Подход к обработке потоковых данных, при котором данные обрабатываются пакетами фиксированного размера, называемыми micro-batches. Является компромиссом между традиционной пакетной обработкой данных и строгим потоковым (streaming) подходом.



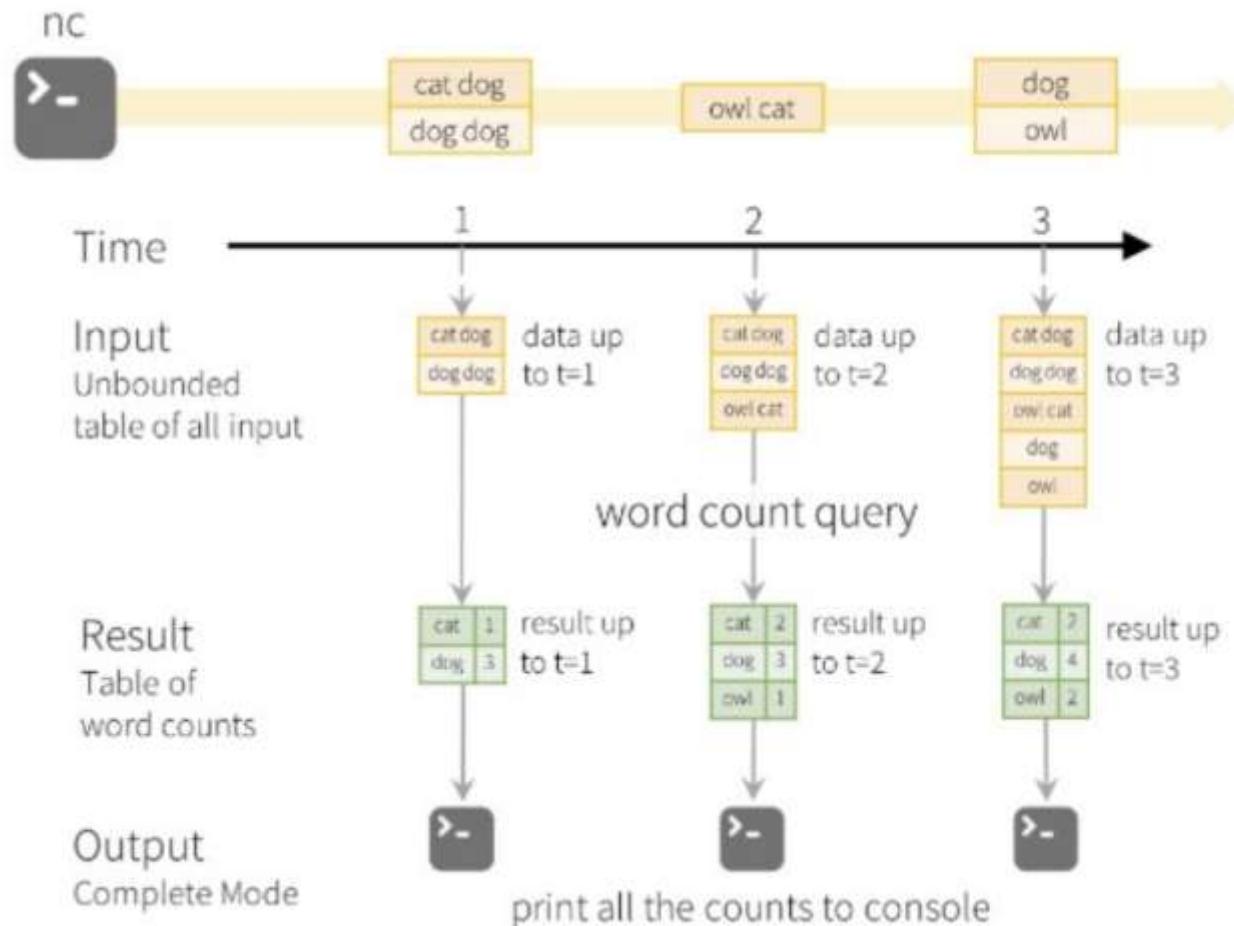
Концепция Spark Streaming



Концепция Spark Streaming - II



Интуитивный пример



Приимеры работы с кодом

```
from pyspark.sql.types import StructType, StringType, IntegerType

schema = StructType().add("name", StringType()).add("age", IntegerType())

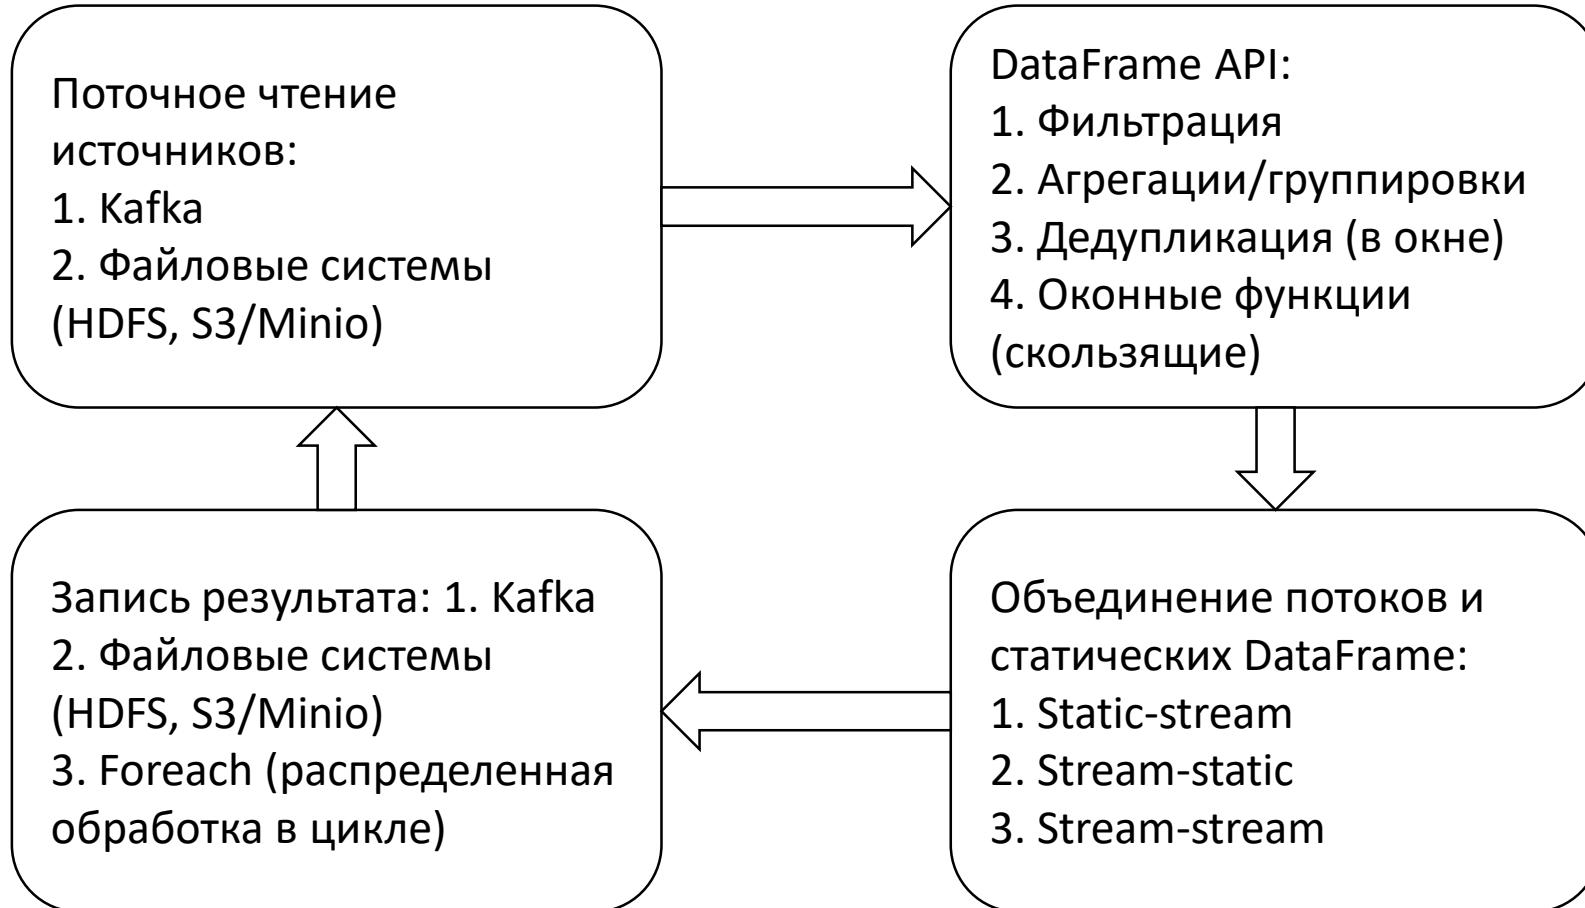
df = spark.readStream \
    .schema(schema) \
    .option("maxFilesPerTrigger", 1) \
    .csv("/path/to/incoming/files")

df_filtered = df.filter("age >= 18")

query = df_filtered.writeStream \
    .format("console") \
    .outputMode("append") \
    .start()

query.awaitTermination()
```

Основные возможности



Достоинства

Единый API для
пакетной и потоковой
обработки

Тolerантность к сбоям
и обработка точно
один раз

Обработка только 1
раз

Интеграция со
стандартными
источниками данных

Интеграция с
экосистемой
Spark/Hadoop

Поддержка
SQLзапросов

Недостатки

Задержка (Latency)

Сложность масштабирования
(обработка огромных
micro-batch)

Меньше строк кода,
чем SQL

Сложность управления
состоянием

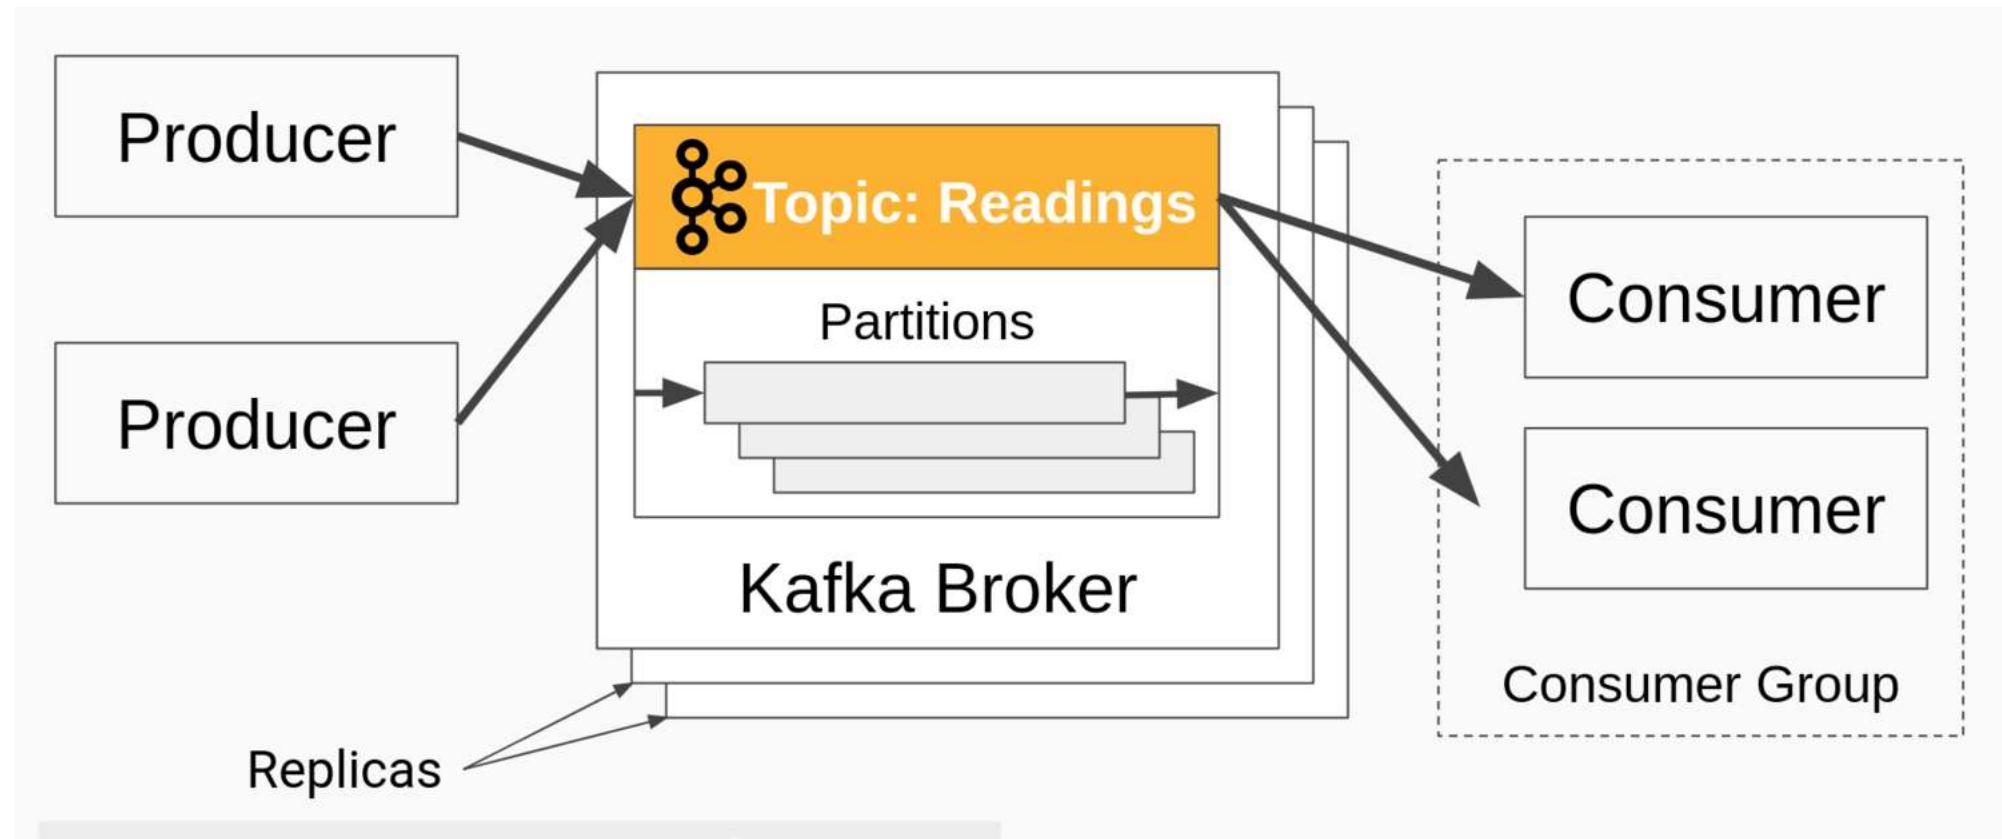
Необходимость знания
экосистемы Spark

Ограничения по
поддержке источников
данных

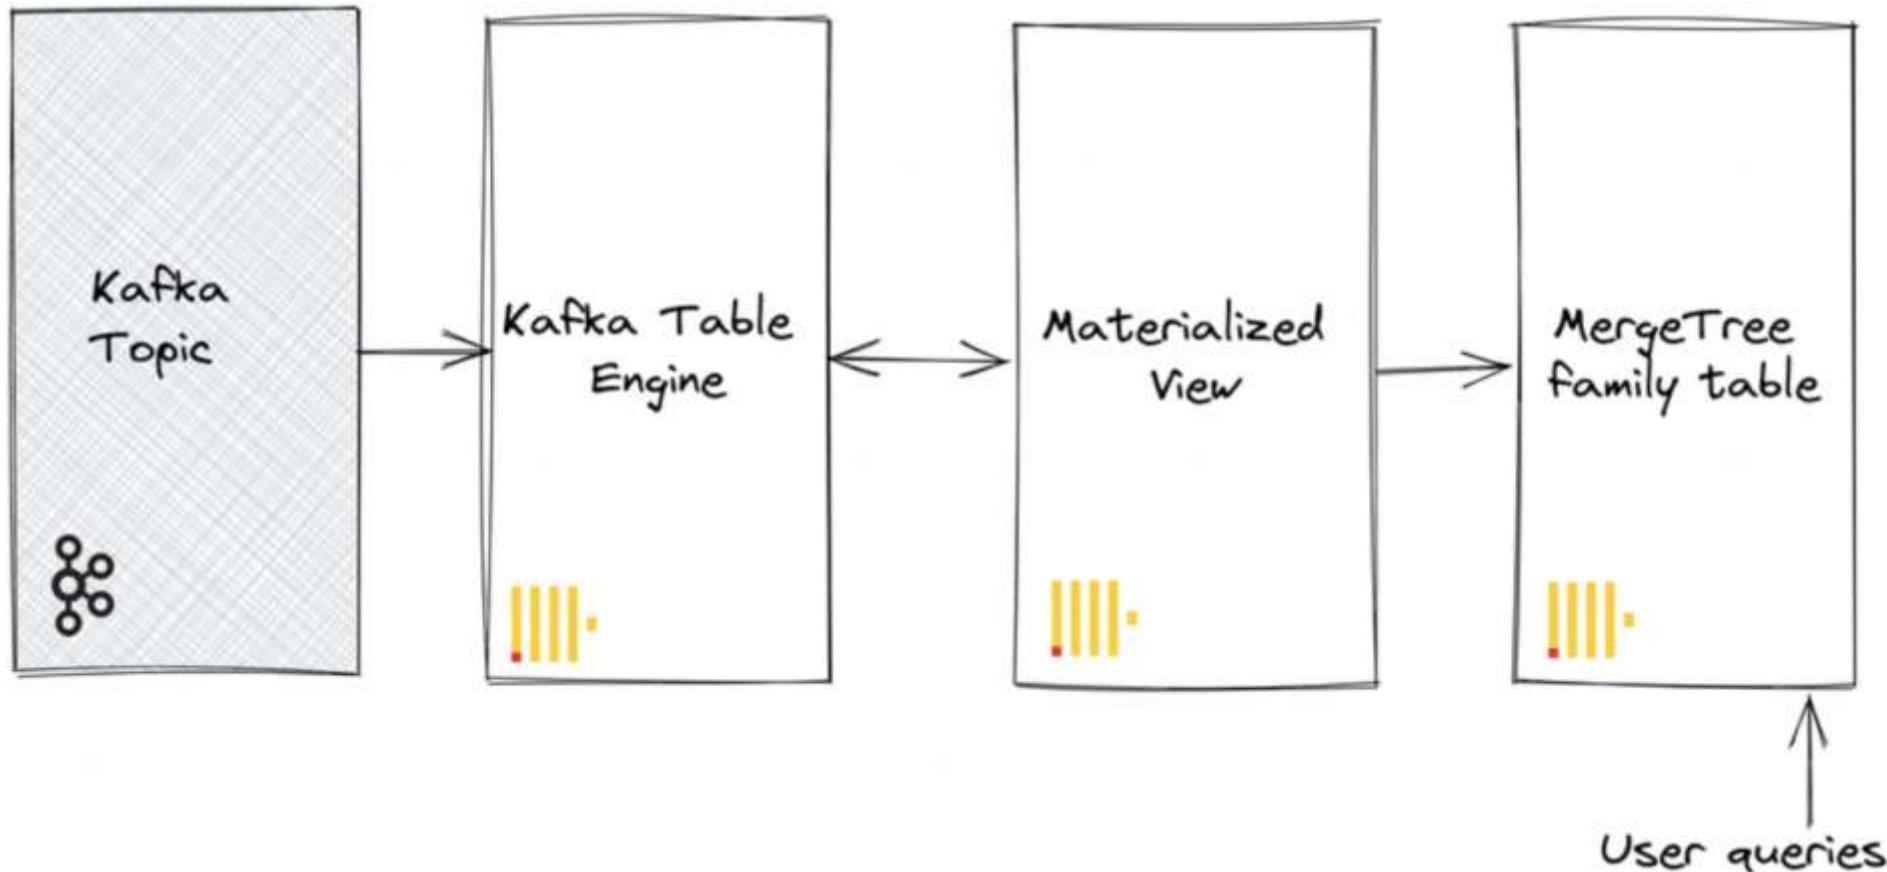
ClickHouse для реалтайм аналитики?

ClickHouse — это высокопроизводительная колоночная система управления базами данных (СУБД) с открытым исходным кодом, предназначенная для онлайн-аналитической обработки (OLAP) данных в реальном времени. Она позволяет быстро обрабатывать миллиарды строк и широкие таблицы, используя SQL-запросы, благодаря хранению данных по столбцам, а не строкам.

RealTime обработка данных через ClickHouse



RealTime обработка данных через ClickHouse



Kafka Engine

-- Consumer

```
CREATE TABLE test.kafka (key UInt64, value UInt64)
ENGINE = Kafka
SETTINGS kafka_broker_list = 'kafka1:19092',
          kafka_topic_list = 'my_topic',
          kafka_group_name = 'my_consumer_group_name',
          kafka_format = 'JSONEachRow',
          kafka_max_block_size = 1048576;
```

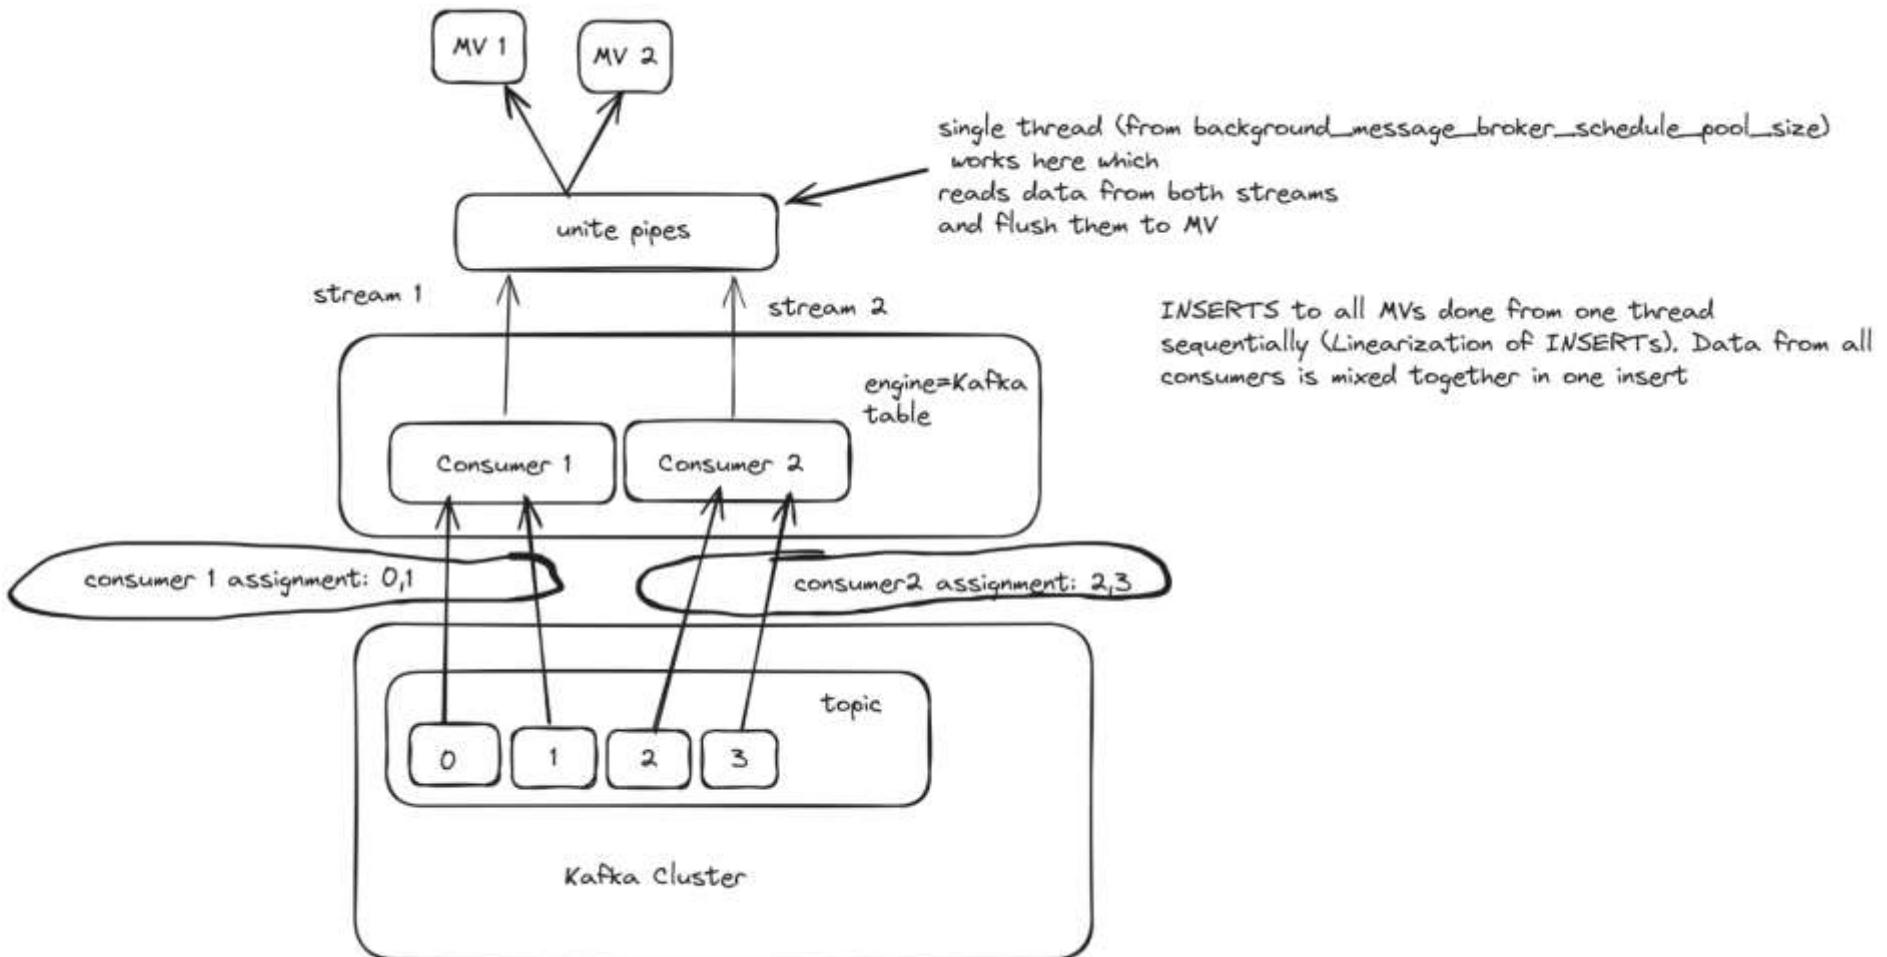
Destination table

```
-- Destination table  
CREATE TABLE test.view (key UInt64, value UInt64)  
ENGINE = MergeTree()  
ORDER BY key;
```

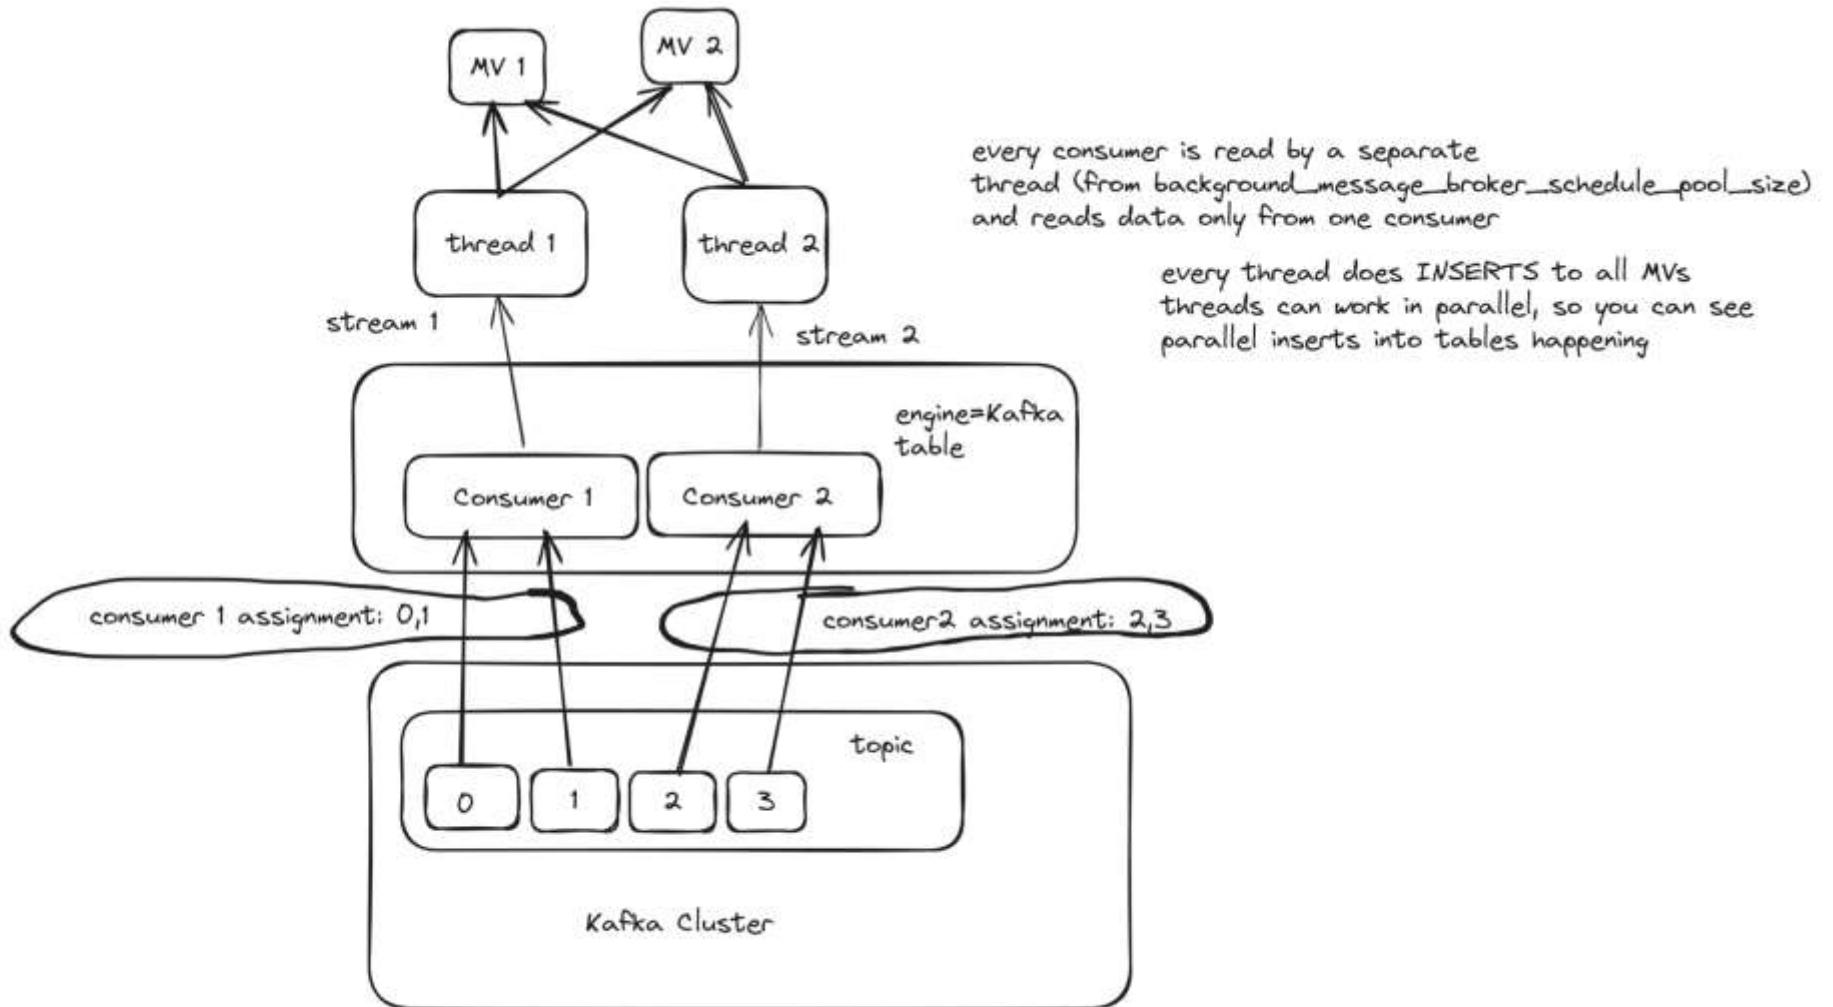
MV

-- Materialized View to move the data from a Kafka topic to a ClickHouse table

```
CREATE MATERIALIZED VIEW test.consumer TO test.view AS  
SELECT * FROM test.kafka;
```



`thread_per_consumer = 0`



`thread_per_consumer = 1`